

LAPORAN PROJECT MACHINE LEARNING
PREDIKSI KECEPATAN MOBIL BERDASARKAN SPESIFIKASI



Dosen Pengampu : Lutfiah Maharani Siniwi, S.Stat., M.stat.

Disusun oleh :

Unaisyah Moulia Wardhani	(K1D024052)
Rifat Fazle Mawla	(K1D024055)
Talenta Nusantara Wijaya	(K1D024057)
Raichan Achmad Rabbani	(K1D024064)
Shaddrina Izzati	(K1D024066)

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO

2026

DAFTAR ISI

DAFTAR ISI.....	i
KATA PENGANTAR.....	iii
BAB I.....	1
PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	1
1.3 Tujuan Penelitian.....	1
1.4 Manfaat Penelitian.....	2
BAB II.....	3
TINJAUAN DATASET	3
2.1 Deskripsi Dataset	3
2.2 Sumber Dataset	3
2.3 Struktur Dataset.....	3
2.4 Variabel Penelitian	3
2.4.1 Variabel Independen	4
2.4.2 Variabel Dependen.....	4
2.5 Jenis Permasalahan Machine Learning	4
BAB III.....	5
METODOLOGI PENELITIAN	5
3.1 Tahapan Penelitian	5
3.2 Perangkat dan Software.....	5
3.3 Pengumpulan Data	5
3.4 Exploratory Data Analysis (EDA)	6
3.5 Data Preprocessing	6
3.5.1 Pemisahan Fitur dan Target	6
3.5.2 Pembagian Data Latih dan Data Uji.....	6
3.5.3 Standardisasi Data.....	7
3.5.4 Validasi Data	7
3.6 Pembangunan Model.....	7
3.7 Hyperparameter Tuning	8
3.8 Evaluasi Model.....	8
BAB IV	10
HASIL DAN PEMBAHASAN.....	10

4.1 Eksplorasi Data dan Hubungan Antar Variabel	10
4.1.1 Statistik Deskriptif.....	10
4.1.2 Distribusi Variabel Target.....	11
4.1.3 Distribusi Variabel Prediktor	12
4.1.4 Analisis Korelasi	13
4.2 Pengembangan Model <i>Machine Learning</i>	13
4.2.1 Pembagian Data	13
4.2.2 <i>Random Forest Default</i>	14
4.2.3 <i>Random Forest Tuned</i>	14
4.2.4 <i>XGBoost Default</i>	15
4.2.5 <i>XGBoost Tuned</i>	16
4.2.6 <i>Support Vector Machine (SVM) Default</i>	16
4.2.7 <i>Support Vector Machine (SVM) Tuned</i>	17
4.3 Evaluasi dan Pemilihan Model Terbaik	18
4.3.1 Perbandingan Kinerja Model	18
4.3.2 Analisis Model Terbaik.....	19
BAB V.....	23
PENUTUP.....	23
5.1 Kesimpulan.....	23
5.2 Saran.....	23
LAMPIRAN.....	25

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga laporan project akhir mata kuliah Machine Learning ini dapat diselesaikan dengan baik dan tepat waktu.

Laporan ini disusun sebagai bentuk pertanggungjawaban atas pelaksanaan project akhir yang menggantikan Ujian Akhir Semester (UAS) pada mata kuliah Machine Learning Kelas B. Dalam project ini, kami menerapkan keseluruhan alur kerja machine learning dengan mengambil studi kasus Prediksi Kecepatan Mobil Berdasarkan Spesifikasi Menggunakan Machine Learning.

Kami menyadari bahwa penyelesaian project ini tidak terlepas dari dukungan dan bimbingan berbagai pihak. Oleh karena itu, kami menyampaikan terima kasih kepada:

1. Ibu Lutfiah Maharani Siniwi, S.Stat., M.Stat. selaku dosen pengampu mata kuliah Machine Learning yang telah membimbing dan memberikan arahan selama proses pengerjaan project ini.
2. Seluruh anggota kelompok yang telah berkontribusi secara aktif dan bekerja sama dengan penuh tanggung jawab dalam setiap tahapan pengerjaan project ini.
3. Berbagai pihak yang tidak dapat disebutkan satu per satu, yang telah memberikan dukungan baik secara langsung maupun tidak langsung.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang bersifat membangun sangat kami harapkan demi perbaikan di masa mendatang. Semoga laporan ini dapat memberikan manfaat dan menjadi referensi yang berguna bagi pembaca, khususnya dalam memahami penerapan Machine Learning untuk memprediksi kecepatan mobil berdasarkan spesifikasi kendaraan.

Purwokerto, Juni 2026

Penyusun

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi pengolahan data mendorong pemanfaatan *Machine Learning* dalam berbagai bidang, termasuk transportasi dan otomotif. Menurut Fauzi, Atmaja, dan Albi (2024), *Machine Learning* telah banyak digunakan untuk membantu proses analisis dan prediksi berbasis data pada sektor transportasi. Penerapan *Machine Learning* pada bidang otomotif terus berkembang karena mampu mengolah data dalam jumlah besar serta mempelajari pola hubungan antarvariabel yang kompleks sehingga dapat dimanfaatkan untuk mendukung proses pengambilan keputusan dan prediksi performa kendaraan.

Pada penelitian ini digunakan dataset yang berisi informasi spesifikasi kendaraan, yaitu *wing_angle_deg*, *drs_active*, *downforce_n*, *drag_n*, dan *stability_index*, dengan variabel target berupa *speed_kmh*. Hubungan antarvariabel tersebut bersifat kompleks sehingga diperlukan metode yang mampu memodelkan hubungan tersebut secara efektif. Pemanfaatan *Machine Learning* memungkinkan proses prediksi dilakukan secara lebih cepat dan akurat dibandingkan pendekatan konvensional sehingga dapat memberikan informasi yang bermanfaat dalam analisis performa kendaraan.

Untuk memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia, penelitian ini menerapkan beberapa algoritma *Machine Learning* serta melakukan optimasi hyperparameter untuk meningkatkan performa model. Hasil dari masing-masing model kemudian dibandingkan menggunakan metrik evaluasi regresi untuk menentukan model dengan performa terbaik dalam memprediksi kecepatan kendaraan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana hubungan antara spesifikasi kendaraan dan kecepatan mobil yang dihasilkan?
2. Bagaimana membangun model *Machine Learning* untuk memprediksi kecepatan mobil berdasarkan spesifikasi kendaraan?
3. Algoritma *Machine Learning* manakah yang memberikan performa prediksi terbaik berdasarkan hasil evaluasi model?

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Menganalisis pengaruh spesifikasi kendaraan terhadap kecepatan mobil.

2. Membangun model *Machine Learning* untuk memprediksi kecepatan mobil berdasarkan spesifikasi kendaraan.
3. Membandingkan performa beberapa algoritma *Machine Learning* dalam melakukan prediksi kecepatan mobil.
4. Menentukan model terbaik berdasarkan hasil evaluasi menggunakan metrik regresi.

1.4 Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah:

1. Memberikan pemahaman mengenai penerapan *Machine Learning* pada bidang otomotif.
2. Mengetahui faktor-faktor spesifikasi kendaraan yang berpengaruh terhadap kecepatan mobil.
3. Menjadi referensi dalam pengembangan model prediksi berbasis data pada bidang kendaraan dan transportasi.
4. Menambah wawasan mengenai penggunaan algoritma *Machine Learning* untuk menyelesaikan permasalahan regresi.

BAB II

TINJAUAN DATASET

2.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset telemetri kendaraan yang berisi informasi mengenai spesifikasi aerodinamika kendaraan dan kecepatan yang dihasilkan. Dataset ini digunakan untuk membangun model *Machine Learning* yang mampu memprediksi kecepatan mobil berdasarkan spesifikasi yang dimiliki kendaraan.

Dataset terdiri dari 150.000 observasi dengan 6 variabel, yaitu 5 variabel fitur (independen) dan 1 variabel target (dependen). Variabel target yang diprediksi adalah kecepatan kendaraan dalam satuan kilometer per jam (km/h).

2.2 Sumber Dataset

Dataset yang digunakan dalam penelitian ini berasal dari data telemetri kendaraan yang memuat parameter aerodinamika kendaraan dan nilai kecepatan kendaraan. Dataset diperoleh dalam format CSV dan digunakan sebagai sumber data utama dalam proses pelatihan serta evaluasi model *Machine Learning*.

2.3 Struktur Dataset

Dataset yang digunakan memiliki 150.000 baris data dan 6 kolom yang terdiri atas satu variabel target dan lima variabel fitur.

Tabel 2.1 Deskripsi Variabel Dataset

No	Variabel	Tipe Data	Keterangan
1	speed_kmh	Numerik	Kecepatan kendaraan (target)
2	wing_angle_deg	Numerik	Sudut sayap kendaraan (derajat)
3	drs_active	Numerik	Status DRS (0 = tidak aktif, 1 = aktif)
4	downforce_n	Numerik	Gaya tekan ke bawah (Newton)
5	drag_n	Numerik	Gaya hambat udara (Newton)
6	stability_index	Numerik	Indeks stabilitas kendaraan

2.4 Variabel Penelitian

Variabel penelitian terdiri atas variabel independen (fitur) dan variabel dependen (target). Variabel independen digunakan sebagai masukan bagi model *Machine Learning*, sedangkan variabel dependen merupakan nilai yang akan diprediksi. Pemilihan variabel

didasarkan pada karakteristik aerodinamika kendaraan yang diduga memengaruhi kecepatan mobil.

2.4.1 Variabel Independen

Variabel independen yang digunakan dalam penelitian ini adalah sebagai berikut:

1. **Wing Angle (wing_angle_deg)**
Menunjukkan sudut sayap kendaraan dalam satuan derajat yang memengaruhi performa aerodinamika kendaraan.
2. **DRS Active (drs_active)**
Menunjukkan status aktivasi *Drag Reduction System* (DRS), dengan nilai 0 untuk tidak aktif dan 1 untuk aktif.
3. **Downforce (downforce_n)**
Merupakan gaya tekan ke bawah yang bekerja pada kendaraan dan diukur dalam satuan Newton (N).
4. **Drag (drag_n)**
Merupakan gaya hambatan udara yang berlawanan arah dengan laju kendaraan.
5. **Stability Index (stability_index)**
Menunjukkan tingkat kestabilan kendaraan selama beroperasi.

2.4.2 Variabel Dependen

Variabel dependen yang digunakan adalah **speed_kmh**, yaitu kecepatan kendaraan dalam satuan kilometer per jam (km/h). Variabel ini menjadi target utama yang diprediksi berdasarkan spesifikasi kendaraan yang digunakan sebagai fitur.

2.5 Jenis Permasalahan Machine Learning

Penelitian ini termasuk dalam kategori supervised learning, yaitu metode pembelajaran mesin yang menggunakan data berlabel untuk melatih model. Berdasarkan jenis target yang digunakan, penelitian ini merupakan permasalahan regresi (*regression*) karena bertujuan memprediksi nilai numerik kontinu berupa kecepatan kendaraan (**speed_kmh**). Untuk memperoleh model dengan performa terbaik, penelitian ini menerapkan beberapa algoritma *Machine Learning* dan melakukan optimasi hyperparameter pada model yang digunakan. Selanjutnya, performa masing-masing model dievaluasi menggunakan metrik *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan koefisien determinasi (R^2) untuk menentukan model yang memberikan hasil prediksi terbaik.

BAB III

METODOLOGI PENELITIAN

3.1 Tahapan Penelitian

Penelitian ini dilakukan untuk membangun model *Machine Learning* yang mampu memprediksi kecepatan mobil berdasarkan spesifikasi kendaraan yang tersedia pada dataset. Proses penelitian dilakukan secara bertahap mulai dari pengumpulan data hingga evaluasi model untuk memperoleh model dengan performa terbaik. Tahapan penelitian yang dilakukan meliputi:

1. Pengumpulan dataset.
2. *Exploratory Data Analysis* (EDA).
3. Data preprocessing.
4. Pembagian data latih dan data uji.
5. Pembangunan model *Machine Learning*.
6. Hyperparameter tuning.
7. Evaluasi model.
8. Analisis hasil dan penarikan kesimpulan.

3.2 Perangkat dan Software

Penelitian ini menggunakan bahasa pemrograman Python sebagai alat utama dalam proses analisis data dan pembangunan model *Machine Learning*.

Tabel 3.2 Perangkat Lunak yang Digunakan

No	Software/Library	Fungsi
1	Python	Bahasa pemrograman utama
2	Pandas	Pengolahan data
3	NumPy	Komputasi numerik
4	Matplotlib	Visualisasi data
5	Seaborn	Visualisasi statistik
6	Scikit-learn	Preprocessing, train-test split, evaluasi model
7	XGBoost	Implementasi model XGBoost dan XGBRF

3.3 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini merupakan dataset telemetri kendaraan yang berisi informasi spesifikasi kendaraan dan kecepatan kendaraan. Dataset terdiri dari 150.000 data dengan enam variabel, yaitu lima variabel fitur dan satu variabel target.

Variabel target yang digunakan adalah `speed_kmh`, sedangkan variabel fitur yang digunakan meliputi `wing_angle_deg`, `drs_active`, `downforce_n`, `drag_n`, dan `stability_index`. Dataset disimpan dalam format CSV dan diolah menggunakan library Pandas.

Jumlah data yang relatif besar memungkinkan model mempelajari pola hubungan antara spesifikasi kendaraan dan kecepatan mobil secara lebih baik sehingga diharapkan menghasilkan prediksi yang akurat.

3.4 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan. Tahap ini bertujuan untuk memperoleh informasi mengenai struktur data, distribusi variabel, serta hubungan antarvariabel yang terdapat dalam dataset.

Pada tahap EDA dilakukan beberapa analisis, antara lain:

1. Pemeriksaan jumlah data dan jumlah variabel.
2. Identifikasi tipe data setiap variabel.
3. Analisis statistik deskriptif.
4. Pemeriksaan nilai kosong (*missing value*).
5. Visualisasi distribusi data.
6. Analisis korelasi antarvariabel.

Melalui EDA, peneliti dapat memahami pola yang terdapat pada data serta mengidentifikasi potensi permasalahan yang dapat memengaruhi proses pembangunan model.

3.5 Data Preprocessing

Data preprocessing merupakan tahap persiapan data sebelum digunakan dalam proses pelatihan model *Machine Learning*. Tahap ini bertujuan untuk memastikan bahwa data berada dalam kondisi yang sesuai untuk proses pemodelan.

3.5.1 Pemisahan Fitur dan Target

Pada tahap ini dataset dipisahkan menjadi variabel fitur (*features*) dan variabel target (*target*). Variabel target yang digunakan adalah `speed_kmh`, sedangkan variabel lainnya digunakan sebagai fitur masukan bagi model.

Proses pemisahan ini dilakukan agar model dapat mempelajari hubungan antara spesifikasi kendaraan dan kecepatan yang dihasilkan.

3.5.2 Pembagian Data Latih dan Data Uji

Setelah dilakukan pemisahan fitur dan target, data kemudian dibagi menjadi data latih (*training data*) dan data uji (*testing data*) menggunakan metode *train-test split*. Pada penelitian ini digunakan proporsi 80% data latih dan 20% data uji. Dari total 150.000 data, sebanyak 120.000 data digunakan sebagai data latih dan 30.000 data

digunakan sebagai data uji. Data latih digunakan untuk membangun model *Machine Learning*, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang belum pernah digunakan sebelumnya.

Pembagian data dengan proporsi 80:20 dilakukan untuk memberikan jumlah data pelatihan yang lebih besar sehingga model dapat mempelajari pola hubungan antarvariabel secara lebih optimal, sementara sebagian data lainnya tetap digunakan untuk menguji kemampuan generalisasi model terhadap data yang tidak digunakan selama proses pelatihan.

3.5.3 Standardisasi Data

Setelah data dibagi menjadi data latih dan data uji, dilakukan proses standardisasi data menggunakan metode *StandardScaler* dari library *Scikit-learn*. Standardisasi bertujuan untuk menyamakan skala antar fitur sehingga setiap variabel memiliki rata-rata (*mean*) mendekati nol dan standar deviasi sebesar satu. Proses ini dilakukan agar perbedaan rentang nilai antar fitur tidak memengaruhi kinerja model dalam mempelajari pola data.

Proses standardisasi dilakukan dengan menghitung parameter rata-rata dan standar deviasi dari data latih, kemudian parameter tersebut digunakan untuk mentransformasikan data latih dan data uji. Dengan demikian, distribusi data menjadi lebih seragam sehingga dapat meningkatkan stabilitas dan kualitas model dalam melakukan prediksi.

3.5.4 Validasi Data

Setelah preprocessing dilakukan, data diperiksa kembali untuk memastikan bahwa seluruh variabel telah berada dalam format yang sesuai dan siap digunakan pada tahap pemodelan. Tahap ini dilakukan untuk meminimalkan kemungkinan kesalahan selama proses pelatihan model.

3.6 Pembangunan Model

Pada tahap ini dilakukan pembangunan model *Machine Learning* menggunakan data latih yang telah melalui proses preprocessing. Model dibangun untuk mempelajari hubungan antara variabel fitur, yaitu *wing_angle_deg*, *drs_active*, *downforce_n*, *drag_n*, dan *stability_index*, terhadap variabel target berupa *speed_kmh*.

Penelitian ini menggunakan algoritma *XGBoost* dan *XGBRF* untuk melakukan prediksi kecepatan kendaraan. Kedua model dilatih menggunakan data latih yang telah disiapkan sebelumnya, kemudian digunakan untuk menghasilkan prediksi pada data uji. Pemilihan algoritma tersebut didasarkan pada kemampuannya dalam memodelkan hubungan

nonlinier antarvariabel serta menghasilkan performa prediksi yang baik pada permasalahan regresi.

Setelah proses pelatihan model selesai dilakukan, hasil prediksi dari masing-masing model selanjutnya dievaluasi menggunakan beberapa metrik evaluasi regresi. Perbandingan hasil evaluasi tersebut digunakan untuk menentukan model yang memiliki performa terbaik dalam memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia.

3.7 Hyperparameter Tuning

Setelah model dibangun, dilakukan proses *hyperparameter tuning* untuk memperoleh kombinasi parameter yang menghasilkan performa terbaik. *Hyperparameter tuning* dilakukan pada model XGBoost dan XGBRF dengan menguji beberapa kombinasi parameter yang memengaruhi proses pembelajaran model. Tujuan dari proses ini adalah meningkatkan kemampuan model dalam mempelajari pola data serta menghasilkan prediksi yang lebih akurat.

Kombinasi parameter yang diuji kemudian dibandingkan berdasarkan hasil evaluasi pada data pelatihan. Parameter terbaik yang diperoleh selanjutnya digunakan untuk membangun model akhir yang akan dievaluasi menggunakan data uji sehingga diharapkan menghasilkan prediksi yang lebih optimal.

3.8 Evaluasi Model

Tahap evaluasi dilakukan untuk mengukur kemampuan model dalam memprediksi kecepatan kendaraan berdasarkan data uji. Hasil prediksi yang diperoleh dari masing-masing model kemudian dibandingkan dengan nilai aktual untuk mengetahui tingkat akurasi dan kesalahan prediksi yang dihasilkan oleh model.

Pada penelitian ini, evaluasi model dilakukan menggunakan beberapa metrik evaluasi regresi, yaitu *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan koefisien determinasi (R^2). MAE digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. MSE digunakan untuk mengukur rata-rata kuadrat kesalahan prediksi, sedangkan RMSE merupakan akar kuadrat dari MSE yang menunjukkan besarnya kesalahan prediksi dalam satuan yang sama dengan variabel target. Selain itu, koefisien determinasi (R^2) digunakan untuk mengetahui kemampuan model dalam menjelaskan variasi data, dimana nilai R^2 yang mendekati satu menunjukkan bahwa model memiliki kemampuan prediksi yang semakin baik.

Hasil evaluasi dari masing-masing model kemudian dibandingkan untuk menentukan model dengan performa terbaik dalam memprediksi kecepatan kendaraan berdasarkan variabel

yang digunakan. Model dengan nilai MAE, MSE, dan RMSE yang lebih kecil serta nilai R^2 yang lebih tinggi dipilih sebagai model terbaik dalam penelitian ini.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data dan Hubungan Antar Variabel

4.1.1 Statistik Deskriptif

	speed_kmh	wing_angle_deg	drs_active	downforce_n	drag_n	stability_index
count	150000	150000	150000	150000	150000	150000
mean	232.568436	20.021099	0.298973	2393.564281	166.173028	91.333445
std	76.46466	8.660498	0.45781	1844.33684	106.49027	24.773129
min	100	5	0	105.17	18.05	0
max	365	35	1	8978.76	519.46	100


Tabel 4.1.1 Statistika Deskriptif

Berdasarkan **Tabel 4.1.1**, dataset yang digunakan terdiri dari 150.000 observasi dengan enam variabel numerik, yaitu satu variabel target (`speed_kmh`) dan lima variabel prediktor (`wing_angle_deg`, `drs_active`, `downforce_n`, `drag_n`, dan `stability_index`). Variabel target `speed_kmh` memiliki rata-rata kecepatan sebesar 232,57 km/jam dengan nilai minimum 100 km/jam dan maksimum 365 km/jam, yang menunjukkan rentang kecepatan kendaraan yang cukup luas.

Variabel `wing_angle_deg` memiliki rata-rata sebesar 20,02° dengan rentang nilai antara 5° hingga 35°. Sementara itu, variabel `drs_active` merupakan variabel biner dengan rata-rata 0,299, yang menunjukkan bahwa sekitar 29,9% observasi berada pada kondisi DRS aktif. Variabel `downforce_n` memiliki rata-rata sebesar 2.393,56 N dengan nilai maksimum mencapai 8.978,76 N, sedangkan variabel `drag_n` memiliki rata-rata sebesar 166,17 N dengan nilai maksimum 519,46 N. Adapun variabel `stability_index` memiliki rata-rata 91,33 dengan rentang nilai 0 hingga 100.

Secara umum, statistik deskriptif menunjukkan bahwa data yang digunakan memiliki variasi yang cukup baik dan mencakup rentang nilai yang luas pada setiap variabel. Variasi tersebut memberikan informasi yang beragam bagi model dalam mempelajari hubungan antara variabel prediktor dengan variabel target. Selain itu, tidak ditemukan nilai yang berada di luar batas logis masing-masing variabel, sehingga dataset dinilai representatif dan memadai untuk mendukung proses pelatihan model serta menghasilkan prediksi kecepatan kendaraan yang akurat.

4.1.2 Distribusi Variabel Target




Gambar 4.1.2 Visualisasi Distribusi Variabel Target

Berdasarkan **Gambar 4.1.2**, variabel `speed_kmh` memiliki distribusi yang relatif merata pada rentang 100 – 365 km/jam. Hal ini terlihat dari tinggi batang histogram yang cenderung seragam di hampir seluruh rentang nilai kecepatan. Kurva kepadatan (*kernel density estimation*) juga menunjukkan pola yang relatif datar tanpa adanya puncak yang dominan.

Distribusi yang merata mengindikasikan bahwa data kecepatan tidak terkonsentrasi pada rentang tertentu, melainkan tersebar secara seimbang pada seluruh observasi. Kondisi ini menunjukkan bahwa dataset mampu merepresentasikan berbagai kondisi kecepatan kendaraan Formula 1, mulai dari kecepatan rendah hingga tinggi. Dengan demikian, variabel target `speed_kmh` memiliki variasi yang cukup baik untuk digunakan dalam proses pelatihan dan evaluasi model machine learning.

Dengan demikian, variabel target `speed_kmh` memiliki variasi yang cukup baik untuk digunakan dalam proses pelatihan dan evaluasi model *machine learning*. Keberagaman nilai kecepatan yang dimiliki memungkinkan model memperoleh informasi yang lebih lengkap sehingga dapat menghasilkan prediksi yang lebih akurat dan memiliki kemampuan generalisasi yang baik terhadap data baru.

4.1.3 Distribusi Variabel Prediktor




Gambar 4.1.3 Visualisasi Distribusi Variabel Prediktor

Berdasarkan **Gambar 4.1.3**, distribusi variabel prediktor menunjukkan karakteristik yang berbeda-beda. Variabel `wing_angle_deg` memiliki distribusi yang relatif merata pada rentang 5° hingga 35°, yang menunjukkan bahwa sudut sayap tersebar secara seimbang pada seluruh observasi. Variabel `drs_active` merupakan variabel biner yang didominasi oleh nilai 0 (DRS tidak aktif), sedangkan nilai 1 (DRS aktif) muncul dalam proporsi yang lebih kecil.

Variabel `downforce_n` dan `drag_n` memiliki distribusi yang cenderung miring ke kanan (*positively skewed*), ditandai dengan banyaknya observasi pada nilai rendah hingga sedang dan semakin sedikit observasi pada nilai yang tinggi. Hal ini menunjukkan bahwa kondisi kendaraan dengan gaya tekan (*downforce*) dan gaya hambat (*drag*) yang sangat besar relatif jarang terjadi.

Sementara itu, variabel `stability_index` didominasi oleh nilai yang mendekati 100, sehingga sebagian besar kendaraan memiliki tingkat stabilitas yang sangat tinggi. Secara keseluruhan, variasi distribusi pada setiap fitur menunjukkan bahwa dataset memiliki keragaman karakteristik yang cukup baik untuk digunakan dalam pembangunan model prediksi kecepatan kendaraan Formula 1. Keragaman tersebut memungkinkan model mempelajari hubungan antarvariabel secara lebih efektif sehingga dapat menghasilkan prediksi yang lebih akurat dan memiliki kemampuan generalisasi yang baik terhadap data baru.

4.1.4 Analisis Korelasi



Gambar 4.1.4 Korelasi *Heatmap*

Berdasarkan **Gambar 4.1.4**, variabel `drag_n` memiliki korelasi positif sangat kuat dengan `speed_kmh` sebesar 0,92, yang menunjukkan bahwa perubahan nilai *drag* memiliki hubungan yang erat dengan perubahan kecepatan kendaraan. Selain itu, `downforce_n` juga memiliki korelasi positif kuat terhadap `speed_kmh` sebesar 0,77. Sebaliknya, `stability_index` memiliki korelasi negatif sedang sebesar $-0,46$, yang mengindikasikan bahwa peningkatan stabilitas cenderung diikuti oleh penurunan kecepatan.

Sementara itu, variabel `wing_angle_deg` ($-0,01$) dan `drs_active` ($0,00$) menunjukkan korelasi yang sangat lemah terhadap `speed_kmh`, sehingga hubungan linear keduanya dengan kecepatan relatif kecil. Di antara variabel prediktor juga terdapat hubungan yang cukup kuat, seperti korelasi antara `downforce_n` dan `drag_n` sebesar 0,89, serta korelasi negatif antara `downforce_n` dan `stability_index` sebesar $-0,77$.

Secara keseluruhan, hasil analisis korelasi menunjukkan bahwa variabel yang paling berhubungan dengan kecepatan kendaraan adalah `drag_n`, `downforce_n`, dan `stability_index`.

4.2 Pengembangan Model *Machine Learning*

4.2.1 Pembagian Data

Sebelum proses pemodelan dilakukan, dataset dibagi menjadi data pelatihan (*training set*) dan data pengujian (*testing set*) dengan proporsi 80:20. Dari total

150.000 observasi, sebanyak 120.000 observasi digunakan sebagai data pelatihan dan 30.000 observasi digunakan sebagai data pengujian. Data pelatihan dan pengujian masing-masing terdiri atas lima variabel prediktor, yaitu *wing_angle_deg*, *drs_active*, *downforce_n*, *drag_n*, dan *stability_index*, serta satu variabel target, yaitu *speed_kmh*. Pembagian data ini bertujuan agar model dapat dilatih menggunakan data pelatihan dan selanjutnya dievaluasi menggunakan data pengujian yang tidak terlibat dalam proses pelatihan, sehingga kinerja model dapat diukur secara lebih objektif.

4.2.2 *Random Forest Default*

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R ²)
0.1298	0.0329	0.1814	1.0000

Tabel 4.2.2 Tabel Evaluasi Model *Random Forest Regression (Default)*

Berdasarkan hasil evaluasi pada **Tabel 4.2.2**, model *Random Forest Regression (Default)* menunjukkan performa yang sangat baik dalam memprediksi kecepatan kendaraan. Hal ini ditunjukkan oleh nilai *Mean Absolute Error* (MAE) sebesar 0,1298 dan *Root Mean Squared Error* (RMSE) sebesar 0,1814, yang mengindikasikan bahwa rata-rata kesalahan prediksi model tergolong sangat kecil. Selain itu, nilai *Mean Squared Error* (MSE) sebesar 0,0329 juga menunjukkan bahwa selisih antara nilai prediksi dan nilai aktual relatif rendah.

Nilai *R-squared* (R²) sebesar 1,0000 menunjukkan bahwa model mampu menjelaskan hampir seluruh variasi pada variabel target *speed_kmh*. Dengan demikian, model *Random Forest Default* memiliki kemampuan prediksi yang sangat tinggi dan mampu menangkap hubungan antara variabel prediktor dengan kecepatan kendaraan secara akurat. Hasil ini menunjukkan bahwa model *Random Forest Default* telah mampu mempelajari pola yang terdapat pada data dengan baik, sehingga dapat digunakan sebagai dasar untuk melakukan proses optimasi lebih lanjut melalui tuning hyperparameter guna memperoleh performa yang lebih optimal.

4.2.3 *Random Forest Tuned*

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R ²)
0.1277	0.0320	0.1789	1.0000

Tabel 4.2.3 Tabel Evaluasi Model *Random Forest Regression (Tuned)*

Untuk memperoleh kombinasi parameter yang optimal, dilakukan proses *hyperparameter tuning* menggunakan metode *RandomizedSearchCV* dengan skema *3-Fold Cross Validation*. Berdasarkan hasil tuning, diperoleh parameter terbaik yaitu $\text{max_depth} = 20$, $\text{min_samples_leaf} = 1$, dan $\text{n_estimators} = 100$. Kombinasi parameter tersebut kemudian digunakan untuk membangun model *Random Forest* yang telah dioptimalkan.

Hasil evaluasi menunjukkan bahwa model *Random Forest Regression (Tuned)* menghasilkan nilai MAE sebesar 0,1277, MSE sebesar 0,0320, RMSE sebesar 0,1789, dan R^2 sebesar 1,0000. Jika dibandingkan dengan model *Random Forest Default*, terjadi penurunan nilai MAE dari 0,1298 menjadi 0,1277 dan penurunan nilai RMSE dari 0,1814 menjadi 0,1789.

Hasil tersebut menunjukkan bahwa proses tuning berhasil meningkatkan performa model meskipun peningkatannya relatif kecil. Hal ini mengindikasikan bahwa model *Random Forest Default* sebenarnya telah memiliki kinerja yang sangat baik, sehingga ruang perbaikan yang dapat dicapai melalui tuning menjadi terbatas. Dengan demikian, model *Random Forest Tuned* merupakan model *Random Forest* dengan performa terbaik pada penelitian ini.

4.2.4 XGBoost Default

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R^2)
0.8343	1.2158	1.1026	0.9998

Tabel 4.2.4 Tabel Evaluasi Model XGBoost (*Default*)

Model XGBoost (*Default*) kemudian digunakan untuk memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia. Berdasarkan hasil evaluasi, model menghasilkan nilai MAE sebesar 0,8343, MSE sebesar 1,2158, RMSE sebesar 1,1026, dan R^2 sebesar 0,9998. Nilai-nilai tersebut menunjukkan bahwa model mampu melakukan prediksi dengan tingkat akurasi yang sangat tinggi, ditandai oleh nilai kesalahan yang relatif kecil dan koefisien determinasi yang mendekati satu.

Meskipun demikian, jika dibandingkan dengan model *Random Forest* yang telah dibangun sebelumnya, performa XGBoost *Default* masih sedikit lebih rendah. Hal ini terlihat dari nilai MAE dan RMSE yang lebih besar dibandingkan *Random Forest*. Namun, nilai R^2 sebesar 0,9998 menunjukkan bahwa model tetap mampu menjelaskan lebih dari 99% variasi pada variabel target *speed_kmh*. Dengan demikian, XGBoost

Default dapat dikategorikan sebagai model yang sangat baik untuk memprediksi kecepatan kendaraan, meskipun belum menjadi model dengan performa terbaik pada tahap ini.

4.2.5 XGBoost Tuned

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R^2)
0.5630	0.5890	0.7675	0.9999

Tabel 4.2.5 Tabel Evaluasi Model XGBoost (*Tuned*)

Untuk meningkatkan performa model, dilakukan *proses hyperparameter tuning* menggunakan metode RandomizedSearchCV. Berdasarkan hasil tuning, diperoleh kombinasi parameter terbaik yaitu `learning_rate = 0,1`, `max_depth = 5`, dan `n_estimators = 100`. Parameter tersebut selanjutnya digunakan untuk membangun model XGBoost yang telah dioptimalkan.

Hasil evaluasi menunjukkan bahwa model XGBoost (*Tuned*) menghasilkan nilai MAE sebesar 0,5630, MSE sebesar 0,5890, RMSE sebesar 0,7675, dan R^2 sebesar 0,9999. Jika dibandingkan dengan model XGBoost *Default*, nilai MAE mengalami penurunan dari 0,8343 menjadi 0,5630 dan nilai RMSE menurun dari 1,1026 menjadi 0,7675. Selain itu, nilai R^2 meningkat dari 0,9998 menjadi 0,9999.

Hasil tersebut menunjukkan bahwa proses tuning berhasil meningkatkan kemampuan prediksi model XGBoost. Penurunan nilai kesalahan prediksi dan peningkatan nilai koefisien determinasi mengindikasikan bahwa model mampu mempelajari hubungan antara variabel prediktor dan variabel target dengan lebih baik. Oleh karena itu, model XGBoost *Tuned* memiliki performa yang lebih baik dibandingkan model XGBoost *Default*.

4.2.6 Support Vector Machine (SVM) Default

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R^2)
3.0704	34.6557	5.8869	0.9941

Tabel 4.2.6 Tabel Evaluasi Model *Support Vector Machine* (*Default*)

Model Support Vector Machine (SVM) *Default* digunakan sebagai salah satu pendekatan untuk memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia. Berdasarkan hasil evaluasi, model menghasilkan nilai MAE sebesar 3,0704, MSE sebesar 34,6557, RMSE sebesar 5,8869, dan R^2 sebesar 0,9941.

Nilai R^2 yang mendekati 1 menunjukkan bahwa model masih mampu menjelaskan sebagian besar variasi pada variabel target speed_kmh. Namun, jika dibandingkan dengan model *Random Forest* maupun XGBoost, nilai MAE dan RMSE pada SVM jauh lebih besar. Hal ini menunjukkan bahwa rata-rata kesalahan prediksi yang dihasilkan SVM lebih tinggi dibandingkan kedua algoritma tersebut.

Meskipun performa SVM masih tergolong baik dengan nilai R^2 di atas 99%, model ini belum mampu mencapai tingkat akurasi yang sama dengan *Random Forest* dan XGBoost. Oleh karena itu, pada tahap ini SVM Default dapat dikatakan memiliki performa yang lebih rendah dibandingkan model berbasis ensemble learning yang digunakan dalam penelitian ini.

4.2.7 Support Vector Machine (SVM) Tuned

<i>Mean Absolute Error</i> (MAE)	<i>Mean Squared Error</i> (MSE)	<i>Root Mean Squared Error</i> (RMSE)	<i>R-squared</i> (R^2)
3.8205	44.3772	6.6616	0.9924

Tabel 4.2.7 Tabel Evaluasi Model *Support Vector Machine (Tuned)*

Untuk meningkatkan performa model, dilakukan proses hyperparameter tuning menggunakan metode *RandomizedSearchCV*. Berdasarkan hasil tuning, diperoleh kombinasi parameter terbaik yaitu $C = 1$ dan $\gamma = \text{'auto'}$. Parameter tersebut kemudian digunakan untuk membangun model *Support Vector Regression (SVR) Tuned*.

Hasil evaluasi menunjukkan bahwa model SVM *Tuned* menghasilkan nilai MAE sebesar 3,8205, MSE sebesar 44,3772, RMSE sebesar 6,6616, dan R^2 sebesar 0,9924. Jika dibandingkan dengan model SVM *Default*, nilai MAE meningkat dari 3,0704 menjadi 3,8205 dan nilai RMSE meningkat dari 5,8869 menjadi 6,6616. Selain itu, nilai R^2 mengalami penurunan dari 0,9941 menjadi 0,9924.

Hasil tersebut menunjukkan bahwa proses tuning tidak berhasil meningkatkan performa model SVM. Sebaliknya, model menghasilkan tingkat kesalahan prediksi yang lebih besar dibandingkan model *default*. Dengan demikian, pada penelitian ini SVM *Default* memiliki performa yang lebih baik dibandingkan SVM *Tuned*, sehingga model default lebih layak digunakan untuk prediksi kecepatan kendaraan.

4.3 Evaluasi dan Pemilihan Model Terbaik

4.3.1 Perbandingan Kinerja Model

Model	MAE	RMSE	R^2
Random Forest (Tuned)	0.127699	0.032019	0.178940
Random Forest (Default)	0.129819	0.032889	0.181353
XGBoost (Tuned)	0.563019	0.588991	0.767457
XGBoost (Default)	0.834255	1.215816	1.102640
SVM (Default)	3.070359	34.655656	5.886906
SVM (Tuned)	3.820525	44.377221	6.661623

STabel 4.8 Tabel Perbandingan Model


Berdasarkan **Tabel 4.3.1**, model Random Forest (*Tuned*) menghasilkan performa terbaik dengan nilai MAE sebesar 0,127699 dan RMSE sebesar 0,032019, yang merupakan nilai kesalahan terendah dibandingkan model lainnya. Model *Random Forest (Default)* menunjukkan performa yang hampir serupa, namun masih memiliki tingkat kesalahan yang sedikit lebih tinggi dibandingkan model yang telah dilakukan tuning.

Sementara itu, model XGBoost mampu memberikan hasil prediksi yang cukup baik, tetapi nilai kesalahannya masih lebih besar dibandingkan *Random Forest*. Di sisi lain, model SVM, baik pada kondisi default maupun setelah dilakukan tuning, memiliki nilai kesalahan yang paling tinggi sehingga menunjukkan performa prediksi yang relatif lebih rendah dibandingkan model lainnya.

Berdasarkan nilai RMSE sebagai metrik utama evaluasi, model *Random Forest (Tuned)* dipilih sebagai model terbaik untuk memprediksi kecepatan kendaraan karena mampu menghasilkan tingkat kesalahan prediksi paling kecil. Hal ini menunjukkan bahwa proses tuning hyperparameter yang dilakukan berhasil meningkatkan kemampuan model dalam mempelajari pola data sehingga menghasilkan prediksi yang lebih akurat dan lebih optimal dibandingkan model lainnya, sehingga model tersebut layak digunakan pada tahap prediksi selanjutnya.

4.3.2 Analisis Model Terbaik

a. *Learning Curve*




Gambar 4.3.2.1 *Learning Curve Model Random Forest (Tuned)*

Berdasarkan **Gambar 4.3.2.1**, nilai *training error* dan *cross-validation error* mengalami penurunan seiring dengan bertambahnya jumlah data pelatihan. Selain itu, selisih antara kedua kurva semakin kecil pada ukuran data yang lebih besar, yang menunjukkan bahwa model *Random Forest (Tuned)* mampu mempelajari pola data dengan baik dan menghasilkan performa yang stabil.

Selisih yang relatif kecil antara *training error* dan *cross-validation error* mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik. Kondisi tersebut menunjukkan bahwa model tidak mengalami *overfitting* maupun *underfitting*, sehingga mampu memberikan hasil prediksi yang konsisten pada data pelatihan maupun data yang belum pernah dilihat sebelumnya.

Secara keseluruhan, pola pada *learning curve* menunjukkan bahwa model *Random Forest (Tuned)* telah memiliki performa yang optimal dan layak digunakan untuk memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia. Hal ini menunjukkan bahwa proses tuning hyperparameter yang dilakukan berhasil meningkatkan kemampuan model dalam menghasilkan prediksi yang akurat dan stabil.

b. Prediksi vs Aktual




Gambar 4.3.2.2 Grafik Prediksi vs Aktual

Berdasarkan **Gambar 4.3.2.2**, titik-titik hasil prediksi berada sangat dekat dengan garis diagonal yang merepresentasikan kondisi prediksi sempurna (*Actual = Predicted*). Hal ini menunjukkan bahwa nilai prediksi yang dihasilkan oleh model *Random Forest (Tuned)* memiliki tingkat kesesuaian yang sangat tinggi terhadap nilai aktual kecepatan kendaraan. Kedekatan antara nilai aktual dan nilai prediksi menunjukkan bahwa model mampu mempelajari pola data dengan baik.

Penyebaran titik yang hampir seluruhnya mengikuti garis diagonal mengindikasikan bahwa model mampu memprediksi kecepatan kendaraan dengan tingkat akurasi yang tinggi. Kondisi tersebut menunjukkan bahwa kesalahan prediksi yang dihasilkan model relatif kecil sehingga hasil prediksi yang diperoleh cenderung konsisten.

Hasil ini sejalan dengan nilai RMSE sebesar 0,1789 dan nilai R^2 sebesar 1,0000, yang menunjukkan bahwa model mampu menjelaskan hampir seluruh variasi pada variabel target. Secara keseluruhan, model *Random Forest (Tuned)* mampu menghasilkan prediksi yang sangat mendekati nilai sebenarnya sehingga layak digunakan sebagai model terbaik untuk memprediksi kecepatan kendaraan berdasarkan spesifikasi yang tersedia.

c. Analisis Residual




Gambar 4.3.2.3 Grafik Analisis Residual

Berdasarkan **Gambar 4.3.2.3**, distribusi residual terpusat di sekitar nilai nol dan membentuk pola yang relatif simetris. Sebagian besar residual berada pada rentang yang sempit di sekitar nol, yang menunjukkan bahwa selisih antara nilai aktual dan nilai prediksi cenderung kecil.

Penyebaran residual yang terfokus di sekitar nol mengindikasikan bahwa model *Random Forest (Tuned)* memiliki tingkat kesalahan prediksi yang rendah dan tidak menunjukkan bias yang signifikan. Dengan demikian, model mampu menghasilkan prediksi kecepatan kendaraan yang akurat dan konsisten pada data pengujian.

Penyebaran residual yang terfokus di sekitar nol mengindikasikan bahwa model *Random Forest (Tuned)* memiliki tingkat kesalahan prediksi yang rendah dan tidak menunjukkan bias yang signifikan. Dengan demikian, model mampu menghasilkan prediksi kecepatan kendaraan yang akurat dan konsisten pada data pengujian.

d. Feature Importance



Gambar 4.3.2.4 Feature Importance Model *Random Forest (Tuned)*

Berdasarkan **Gambar 4.3.2.4**, variabel *drag_n* memiliki tingkat kepentingan tertinggi dalam model *Random Forest (Tuned)*, sehingga menjadi faktor yang paling berpengaruh dalam memprediksi kecepatan kendaraan. Sementara itu, variabel *wing_angle_deg*, *drs_active*, *downforce_n*, dan *stability_index* memiliki kontribusi yang lebih kecil.

Secara keseluruhan, hasil *feature importance* menunjukkan bahwa model *Random Forest (Tuned)* mampu mengidentifikasi variabel yang paling relevan terhadap target prediksi, sehingga dapat menghasilkan prediksi yang lebih akurat.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa metode *machine learning* dapat digunakan untuk memprediksi kecepatan kendaraan Formula 1 berdasarkan spesifikasi aerodinamika kendaraan. Dataset yang digunakan terdiri dari 150.000 observasi dengan lima variabel prediktor, yaitu *wing_angle_deg*, *drs_active*, *downforce_n*, *drag_n*, dan *stability_index*, serta satu variabel target berupa *speed_kmh*. Hasil eksplorasi data menunjukkan bahwa dataset memiliki karakteristik yang baik dan variasi data yang cukup sehingga dapat digunakan dalam proses pembangunan model prediksi.

Penelitian ini berhasil membangun dan membandingkan beberapa model, yaitu Random Forest, XGBoost, dan *Support Vector Machine* (SVM), baik dalam kondisi *default* maupun setelah dilakukan *hyperparameter tuning*. Evaluasi model dilakukan menggunakan metrik MAE, MSE, RMSE, dan koefisien determinasi (R^2). Berdasarkan hasil pengujian, model Random Forest (Tuned) memberikan performa terbaik dengan nilai MAE sebesar 0,127699, MSE sebesar 0,032019, RMSE sebesar 0,178940, dan nilai R^2 sebesar 1,0000. Hasil tersebut menunjukkan bahwa model mampu menghasilkan prediksi dengan tingkat kesalahan yang sangat rendah dibandingkan model lainnya.

Analisis lebih lanjut terhadap model terbaik menunjukkan bahwa *Random Forest* (Tuned) memiliki kemampuan generalisasi yang baik. Hal ini ditunjukkan oleh *learning curve* yang stabil, distribusi residual yang terpusat di sekitar nilai nol, serta tidak adanya indikasi *overfitting* maupun *underfitting*. Selain itu, hasil *feature importance* menunjukkan bahwa variabel *drag_n* merupakan faktor yang paling berpengaruh dalam memprediksi kecepatan kendaraan, sedangkan variabel lainnya memiliki kontribusi yang relatif lebih kecil. Dengan demikian, model *Random Forest* (Tuned) mampu menghasilkan prediksi yang akurat, stabil, dan konsisten sehingga layak digunakan sebagai model terbaik dalam penelitian ini.

Hasil penelitian ini juga menunjukkan bahwa penerapan *machine learning* pada bidang otomotif mampu memberikan hasil prediksi yang sangat baik berdasarkan data spesifikasi kendaraan yang tersedia. Keberhasilan model *Random Forest* (Tuned) dalam menghasilkan prediksi yang akurat menunjukkan bahwa hubungan antara karakteristik aerodinamika kendaraan dan kecepatan dapat dipelajari dengan baik oleh model.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya. Penelitian berikutnya dapat

menggunakan dataset yang lebih beragam dan mendekati kondisi nyata sehingga model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik. Selain itu, penambahan variabel lain yang berkaitan dengan performa kendaraan, seperti kondisi lintasan, temperatur ban, kondisi cuaca, dan parameter teknis lainnya dapat dipertimbangkan untuk meningkatkan akurasi prediksi.

Penelitian selanjutnya juga dapat mencoba algoritma *machine learning* lainnya, seperti LightGBM, CatBoost, maupun metode berbasis *deep learning* untuk membandingkan performanya dengan model yang digunakan pada penelitian ini. Selain itu, metode optimasi *hyperparameter* yang berbeda dapat digunakan untuk memperoleh kombinasi parameter yang lebih optimal sehingga performa model dapat ditingkatkan.

Selain berfokus pada peningkatan akurasi model, penelitian selanjutnya dapat melakukan analisis yang lebih mendalam mengenai pengaruh masing-masing variabel terhadap kecepatan kendaraan. Pemanfaatan data telemetri yang diperoleh secara real-time juga dapat menjadi alternatif untuk menghasilkan model yang lebih adaptif terhadap berbagai kondisi kendaraan dan lintasan.

Secara umum, hasil penelitian ini diharapkan dapat menjadi referensi bagi penelitian selanjutnya dalam penerapan *machine learning* pada bidang otomotif dan transportasi. Model yang dihasilkan juga dapat dikembangkan lebih lanjut sebagai dasar dalam pembangunan sistem prediksi performa kendaraan yang mampu memberikan hasil secara cepat, akurat, dan konsisten.

LAMPIRAN

Lampiran 1: Link AI

<https://chatgpt.com/c/6a3c2f08-4d38-83ec-b727-03bfffad5732>

<https://chatgpt.com/share/6a3c4a2a-7858-83ec-9ddd-ef7f46ec537a>

Lampiran 2: Link GitHub

https://github.com/rifatfazlemawla005-creator/F1_Analysis